FUNDAÇÃO GETULIO VARGAS
ESCOLA DE MATEMÁTICA APLICADA

GIANLUCCA DEVIGILI

DESENVOLVIMENTO DE UM REPOSITÓRIO UNIFICADO DE DADOS PÚBLICOS

Rio de Janeiro
2023

GIANLUCCA DEVIGILI

DESENVOLVIMENTO DE UM REPOSITÓRIO UNIFICADO DE DADOS PÚBLICOS

Trabalho de conclusão de curso apresentada para a Escola de Matemática Aplicada (FGV/EMAp) como requisito para o grau de bacharel em Ciência de Dados e Inteligência Artificial.

Área de estudo: ciência de dados.

Orientador: Júlio César Chaves

Rio de Janeiro

2023

Ficha catalográfica elaborada pela BMHS/FGV

Devigili, Gianlucca
DESENVOLVIMENTO DE UM REPOSITÓRIO UNIFICADO DE DADOS PÚBLICOS: / Gianlucca Devigili. – 2023.
31f.

Trabalho de Conclusão de Curso – Escola de Matemática Aplicada.

Advisor: Júlio César Chaves.
Includes bibliography.

1. Matemática 2. Aplicada 2. na matemática I. Sobrenome professor, Nome professor II. Escola de Matemática Aplicada III. DESENVOLVIMENTO DE UM REPOSITÓRIO UNIFICADO DE DADOS PÚBLICOS

GIANLUCCA DEVIGILI

DESENVOLVIMENTO DE UM REPOSITÓRIO UNIFICADO DE DADOS PÚBLICOS:

Trabalho de conclusão de curso apresentada para a Escola de Matemática Aplicada (FGV/EMAp) como requisito para o grau de bacharel em Ciência de Dados e Inteligência Artificial.

Área de estudo: ciência de dados.

E aprovado em dd/mm/yyyy
Pela comissão organizadora

Júlio César Chaves
Escola de Matemática Aplicada da Fundação
Getulio Vargas - EMAp/FGV

Rodolpho Guedon Tobler
Instituto Brasileiro de Economia da
Fundação Getulio Vargas - IBRE/FGV

Andrea Diniz da Silva
Escola Nacional de Ciências Estatísticas do
Instituto Brasileiro de Geografia e
Estatística - ENCE/IBGE

Dedico esta dissertação aos meus pais, Ricardo e Karina, sem vocês eu não teria chegado até aqui.

Agradecimentos

Aos meus pais, Ricardo e Karina, por todo o apoio e incentivo desde criança, estando presentes em cada uma das minhas conquistas. Agradeço também meu orientador, professor Júlio, pelo auxílio e pelos conselhos ao longo de minha jornada acadêmica e profissional, tanto na iniciação científica quanto no desenvolvimento do presente trabalho. Ao CDMC, por ter me proporcionado a possibilidade de estudar na FGV. Por fim, agradeço todos os amigos e professores que de alguma forma fizeram parte de minha vida.

"So once you do know what the question actually is, you'll know what the answer means."

Douglas Adams

Resumo

Abstract

Lista de ilustrações

Lista de tabelas

Lista de abreviaturas e siglas

API	*Application Programming Interface* (Interface de programação de aplicações)
ASCII	*American Standard Code for Information Interchange* (Código Padrão Americano para o Intercâmbio de Informação)
ELT	*Extract Load Transform* (Extrair, Carregar e Transformar)
ETL	*Extract Transform Load* (Extrair, Transformar e Carregar)
HTTP	*Hypertext Transfer Protocol*
IBGE	Instituto Brasileiro de Geografia e Estatística
ID	Identificador
JSON	*JavaScript Object Notation* (Notação de Objeto JavaScript)
MB	*Megabyte*
NoSQL	*Not Only Structured Query Language*
ODS	*Open Document Spreadsheet*
ONU	Organização das Nações Unidas
PNAD	Pesquisa Nacional por Amostra de Domicílios
SC	Estado de Santa Catarina
SSL	*Secure Sockets Layer*
UF	Unidade Federativa ou Unidade da Federação
URL	*Uniform Resource Locator* (localizador uniforme de recursos)

Sumário

1 Introdução

No cenário altamente digitalizado no qual a humanidade se insere atualmente, um volume gigantesco de informação é gerado diariamente e a análise de dados é cada vez uma ferramenta crucial inúmeras atividades dos mais diversos setores da sociedade. Empresas utilizam os dados para a tomada de decisões, análises de mercado e criação de estratégias, governos se baseiam neles para a aplicação de políticas públicas, pesquisadores para embasar suas pesquisas e programadores para treinar modelos de *machine learning*, por exemplo. Em suma, a análise de dados auxilia indivíduos e organizações, gerando *insights*, conhecimento e valor para eles e servindo como base para responder as mais diversas perguntas.

Contudo, a abundância de dados não implica em sua qualidade e acessibilidade; pelo contrário, frequentemente, o caminho entre a informação e a geração de conhecimento a partir dela se torna-se longo e complexo. Raramente se encontra um conjunto de dados prontos para a análise e uso imediato. Além disso, documentação escassa ou até mesmo inexistente e a falta de metadados é uma realidade comum, que acaba por gerar diversas tentativas frustradas de se utilizarem *datasets* com o intuito de responder uma pergunta e perceber-se, apenas após considerável esforço, que o conjunto de dados que se tem em mãos não será capaz de proporcionar valor.

Outro problema comum é quanto à estrutura de armazenamento. Bancos de dados transacionais ou *Not Only Structured Query Language* (NoSQL) tem um formato focado em funcionalidade, velocidade de transação e normalização, contudo estes formatos geralmente não atendem a necessidade de analistas e cientistas de dados, já que nestes casos é melhor o sacrifício da economia em espaço de armazenamento em prol da simplificação e eficiência de *queries* devido ao seu volume maior. E às vezes a estrutura no qual os daods são armazenados é ainda mais inóspita que um *dataset* "sujo" ou um modelo com dezenas de tabelas, fazendo com que o usuário deles seja obrigado à ter conhecimento técnico e realizar um trabalho que às vezes dura meses apenas para conseguir iniciar seu trabalho.

Tendo em vista as possíveis dificuldades ao se deparar com um problema de dados, bem como a importância dos dados públicos para os mais diversos tipos de usuário, o presente trabalho objetiva a exploração e tratamento de duas diferentes fontes de dados do Instituto Brasileiro de Geografia e Estatística (IBGE): A *Application Programming Interface* (API) de serviço de dados (IBGE, 2017) e os microdados, que representam os dados das respostas de cada um dos entrevistados, facilitando o estudo dessas bases e possibilitando um encurtamento do caminho entre a informação e a geração de conhecimento.

1.1 O formato dos dados do IBGE

Os dados do Instituto Brasileiro de Geografia e Estatística são disponibilizados em dois formatos: os microdados e os agregados que, em suma, representam a mesma informação, diferindo apenas em termos de granularidade.

Os microdados "consistem no menor nível de desagregação dos dados de uma pesquisa, retratando, sob a forma de códigos numéricos, o conteúdo dos questionários, preservado o sigilo estatístico com vistas à não individualização das informações." (IBGE, 201-?). Ou seja, cada linha de um arquivo de microdados representa o conjunto de respostas de um único entrevistado dentro de uma determinada pesquisa, bem como informações calculadas à partir do que foi amostrado, como renda *per capita* e valor do aluguel em salários mínimos, por exemplo.

Por sua vez, os agregados são agrupamentos desses microdados de acordo com determinados critérios. A *Application Programming Interface* (API) do serviço de dados do IBGE[1] disponibiliza cada variável consolidada de acordo com a pesquisa realizada e respectiva periodicidade, além de agregações de caráter geográfico, indo desde grande região (p. ex. Norte, Sul, *etc.*) até o grão de município ou distrito municipal, quando aplicável.

Em termos geográficos, enquanto os agregados alcançam apenas até o nível de município, enquanto os microdados alcançam o nível de setor censitário, que são descritos por Encarnação (2010) no Guia do Censo como "unidades territoriais estabelecidas para fins de controle cadastral, situadas em um único quadro urbano ou rural, com dimensão e número de domicílios [...]".

Neste contexto, a principal distinção dos dois formatos é o seu nível de detalhe e sua principal vantagem e desvantagem residem no *tradeoff* entre detalhamento e volume. Os microdados, por apresentarem uma granularidade menor, permitem análises mais específicas porém requisitando um maior poder computacional e ocupando um maior espaço de armazenamento. Enquanto isso, os dados agregados já se encontram pré-processados de acordo com seus respectivos pesos amostrais e são mais leves em termos de memória e armazenamento, contudo reduzindo as possibilidades de análise conforme a agregação aumenta.

[1] Disponível em <https://servicodados.ibge.gov.br/api/docs/>. Acessado em 30 de set. de 2023.

2 Objetivo Geral

Tendo em vista a importância dos dados públicos, em especial os do censo demográfico promovido pelo IBGE, o presente trabalho objetiva a criação de um repositório público de dados contendo os conjuntos de dados devidamente tratados e transformados em formato tabular. O repositório contendo os arquivos de código utilizados para o desenvolvimento do trabalho, bem como os dados, se encontra em: <github.com/GDevigili/TCC-IBGE>.

2.1 Objetivos Específicos

- Estudar diferentes estratégias de aquisição de dados censitários do IBGE;
- Carregar os dados do IBGE via API e processá-los de forma a reestruturar eles em formato tabular;
- Codificar um *script* capaz de ler e associar *labels* aos respectivos microdados de modo a gerar um arquivo de dados do *Stata*;
- Demonstrar o uso de ambos conjuntos de dados através de um estudo de caso, demonstrando as diferenças de abrangência e utilização dos dois formatos estudados (API e microdados), gerando visualizações e estatísticas básicas.

3 Metodologia

Como discutido anteriormente, as diferentes formas nas quais os dados censitários, bem como de outras pesquisas do IBGE, são disponibilizados, se diferem basicamente quanto ao seu grão e formato, sendo os agregados disponibilizados via API no formato JSON, enquanto os microdados em arquivos de texto em um formato compactado que será explicado em detalhes na seção 3.2. Dessa forma, duas diferentes abordagens foram tomadas no decorrer do desenvolvimento do trabalho: a de coletar os dados através da API e a de baixar os arquivos de microdados do IBGE e processá-los para então criar os conjuntos de dados disponíveis no repositório.

3.1 APIs do serviço de dados do IBGE

O IBGE oferece ao todo 17 APIs em seu serviço de dados, incluindo a de Agregados, citada anteriormente, a de Localidades, que inclui os códigos dos vários níveis de localidade (p. ex. unidade federativa (UF), macrorregião, município), a de Metadados, incluindo informações como periodicidade e variáveis disponíveis em cada uma das pesquisas disponíveis na API, entre outras. Nestas APIs é possível, através de *Uniform Resource Locators* (URLs) gerar requisições por meio de bibliotecas como a *requests* do *python* para obter os dados da API no formato *Javascript Object Notation* (JSON). Por exemplo, ao fazer uma requisição à API de localidades utilizando o URL `servicodados.ibge.gov.br/api/v1/localidades/distritos` obteremos uma lista de valores no formato exemplificado em *Listing* 1:

```
{"id":421400310, "nome":"Mirador",
  "municipio":{"id":4214003,"nome":"Presidente Getúlio",
    "microrregiao":{"id":42011,"nome":"Rio do Sul",
      "mesorregiao":{"id":4204,"nome":"Vale do Itajaí",
        "UF":{"id":42, "sigla":"SC","nome":"Santa Catarina",
          "regiao":{"id":4, "sigla":"S", "nome":"Sul"}}}},
    "regiao-imediata":{"id":420023, "nome":"Ibirama - Presidente
        Getúlio",
      "regiao-intermediaria":{"id":4207, "nome":"Blumenau",
          "regiao":{"id":4, "sigla":"S","nome":"Sul"}}}}
}
```

Listing 1 – Exemplo de resultado de uma requisição da API de localidades.

Por mais que a formatação JSON tenha uma praticidade maior em um ponto de vista transacional ou orientado à objetos, ele não é ideal para o uso analítico por conta de

uma certa complexidade intrínseca para a navegação pelos dados e necessitando de certo trabalho para a interpretação dos mesmos.

Dado que normalização não é uma prioridade quando se trata de análise, mas sim a simplicidade de na hora de se criarem consultas, foi aplicado à *string* de resultados da requisição um processo de *unnesting* (em português desaninhamento), cujo algoritmo se encontra no *listing* 3 do apêndice A. Tal processo é o oposto do conceito conhecido por *nesting* e consiste de, recursivamente, subir o nível de aninhamento (*nesting-level*) de uma entrada, para o nível de seu nível imediatamente superior, até que todos os valores estejam alinhados.

Por exemplo, aplicando o algoritmo de *unnesting* juntamente com a função `make_df()` (*listing* A.4), gera um *DataFrame* como a tabela 1, com todos os dados em um mesmo *nesting-level*.

id-distrito	nome-distrito	id-municipio	nome-municipio	···	nome-regiao
421400310	Mirador	4214003	Presidente Getúlio	···	Sul
420690010	Dalbérgia	4206900	Ibirama	···	Sul

Tabela 1 – Exemplo dos dados de localidade em formato tabular. Fonte: Dados do autor (2023).

Um certo problema que pode ainda ocorrer é que, mesmo após o *unnesting*, os dados em JSON podem conter também elementos em formato de lista, gerando assim uma coluna na tabela de resultado que possui em si uma lista de valores. Portanto se faz necessário um segundo tratamento para estes casos, que é facilmente resolvido armazenando o conjunto de dados dentro de um objeto do tipo *DataFrame* da biblioteca *pandas* da linguagem *python* e utilizar o método pandas.DataFrame().explode()[1] de modo a converter elementos *list-like* que possam existir dentro das colunas em linhas, copiando os demais valores, como é exemplificado pela figura 1.

Nota-se que os valores "explodidos" continuam aninhados, portanto nesse caso foi necessário reaplicar a função unnest_json() de modo a separar adequadamente os dados. O processo completo é uma sequência de aplicação dessas duas funções conforme o necessário até termos um *DataFrame* completamente desaninhado.

Das 17 APIs disponíveis, foram carregados dados das APIs de localidades, países, agregados e metadados.

A API de localidades retorna as informações referentes aos identificadores geográficos do país definidos pelo IBGE, utilizados para identificar a área na qual foram coletados

[1] Documentação disponível em <pandas.pydata.org/docs/reference/api/pandas.DataFrame.explode.html>, código fonte disponível em <github.com/pandas-dev/pandas/blob/v2.1.1/pandas/core/frame.py#L9432-L9558>. Acessado em 30 de set. 2023.

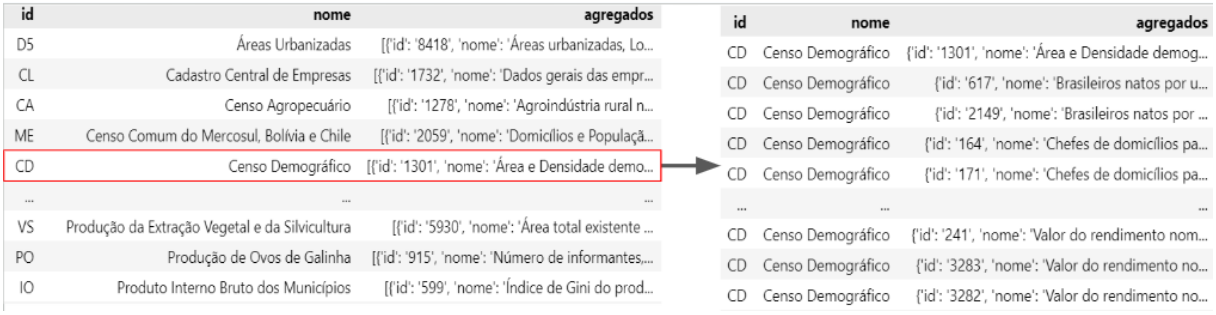

id	nome	agregados
D5	Áreas Urbanizadas	[{'id': '8418', 'nome': 'Áreas urbanizadas, Lo...
CL	Cadastro Central de Empresas	[{'id': '1732', 'nome': 'Dados gerais das empr...
CA	Censo Agropecuário	[{'id': '1278', 'nome': 'Agroindústria rural n...
ME	Censo Comum do Mercosul, Bolívia e Chile	[{'id': '2059', 'nome': 'Domicílios e Populaçã...
CD	Censo Demográfico	[{'id': '1301', 'nome': 'Área e Densidade demo...
...	...	...
VS	Produção da Extração Vegetal e da Silvicultura	[{'id': '5930', 'nome': 'Área total existente ...
PO	Produção de Ovos de Galinha	[{'id': '915', 'nome': 'Número de informantes,...
IO	Produto Interno Bruto dos Municípios	[{'id': '599', 'nome': 'Índice de Gini do prod...

id	nome	agregados
CD	Censo Demográfico	{'id': '1301', 'nome': 'Área e Densidade demog...
CD	Censo Demográfico	{'id': '617', 'nome': 'Brasileiros natos por u...
CD	Censo Demográfico	{'id': '2149', 'nome': 'Brasileiros natos por ...
CD	Censo Demográfico	{'id': '164', 'nome': 'Chefes de domicílios pa...
CD	Censo Demográfico	{'id': '171', 'nome': 'Chefes de domicílios pa...
...	...	...
CD	Censo Demográfico	{'id': '241', 'nome': 'Valor do rendimento nom...
CD	Censo Demográfico	{'id': '3283', 'nome': 'Valor do rendimento no...
CD	Censo Demográfico	{'id': '3282', 'nome': 'Valor do rendimento no...

Figura 1 – Exemplo do uso do método pandas.DataFrame().explode(). Fonte: Dados do autor (2023).

em praticamente todas as pesquisas do órgão. Esse serviço de dados possui ao todo quatro possíveis requisições nas quais os dados são separados por distritos, subdistritos, região metropolitana e região integrada de desenvolvimento. Os conjuntos de dados derivados podem ser juntados entre si através do identificador mais específico presentes nelas, sendo o ID do distrito nas duas primeiras e o id do município nas outras duas.

Contendo 34 indicadores socioeconômicos dos 193 países membros da Organização das Nações Unidas (ONU) a API de países é a única que não utiliza apenas dados coletados pelo próprio IBGE e que também possui traduções em Espanhol e Inglês. Como uma requisição comum solicita a especificação dos países e/ou das variáveis desejadas, a estratégia adotada foi primeiramente obter todos os códigos distintos de países para posteriormente realizar uma requisição para cada país contendo todos os possíveis indicadores e concatenando todos os resultados em um único conjunto de dados. O código completo pode ser encontrado no *listing* A.6.

A carga mais elaborada foi a de agregados, onde foi necessário primeiramente selecionar os IDs dos agregados, totalizando 8442 agregados de 68 pesquisas, cada qual contendo diversas variáveis e séries temporais. Então, obtidos os identificadores, foram requisitados à API os metadados de cada pesquisa. Tendo os dados de nível e o ID do agregado foi então possível usar a URL 'https://servicodados.ibge.gov.br/api/v3/agregados/ {agregado}/variaveis?localidades={nivel}[all]', onde `{agregado}` e `{nivel}` são parâmetros passados conforme os metadados obtidos.

O resultado da requisição acima, transformado em *DataFrame* é o mostrado na figura 2. A coluna mais importante é de resultados, que irá conter duas listas de valores: classificações, contendo metadados acerca da variável, e, novamente, resultados, que por sua vez também contem listas, mas dessa vez com as séries dos valores numéricos.

Aplica-se então o método `explode()` ao *DataFrame* até termos os valores das séries distribuídos em uma coluna por ano, que, para normalizar a tabela, é executado o método `melt()` para criar-se uma coluna de período e outra de valor. O resultado final é um conjunto de dados com as colunas variável, unidade, id, nome e nível geográfico da localidade (p. ex. Município, UF, *etc.*), ano e valor.

	id	variavel	unidade	resultados
0	1488	Mulheres de 10 anos ou mais de idade que vivia...	Pessoas	[{'classificacoes': [{'id': '1', 'nome': 'Situ...
1	1489	Mulheres de 10 anos ou mais de idade que vivia...	Pessoas	[{'classificacoes': [{'id': '1', 'nome': 'Situ...
2	1514	Filhos tidos pelas mulheres de 10 anos ou mais...	Pessoas	[{'classificacoes': [{'id': '1', 'nome': 'Situ...
3	1515	Filhos tidos nascidos vivos pelas mulheres de ...	Pessoas	[{'classificacoes': [{'id': '1', 'nome': 'Situ...
4	1525	Filhos tidos nascidos vivos pelas mulheres de ...	Pessoas	[{'classificacoes': [{'id': '1', 'nome': 'Situ...
5	1526	Filhos tidos nascidos mortos pelas mulheres de...	Pessoas	[{'classificacoes': [{'id': '1', 'nome': 'Situ...
6	1527	Filhos tidos pelas mulheres de 10 anos ou mais...	Pessoas	[{'classificacoes': [{'id': '1', 'nome': 'Situ...

Figura 2 – Tabela de dados após primeira requisição para a carga dos agregados. Fonte: Dados do Autor (2023).

3.2 Microdados do Censo Demográfico

Os dados fornecidos pela API de agregados consistem essencialmente na consolidação das respostas individuais de cada um dos entrevistados durante o processo de recenseamento de acordo com critérios locacionais, com seu menor grau de agregação sedo município. Tais informações são organizadas em um formato denominado pelo IBGE como microdados e são disponibilizados através do portal de produtos estatísticos da instituição[2], estando disponibilizados em diversas pastas compactadas em formato *.zip* que contém os arquivos de texto nos quais se encontram os dados. No entanto, os dados daqueles arquivos não estão imediatamente prontos para a utilização tal qual uma planilha ou um arquivo CSV, mas sim em um formato comprimido, onde os valores categóricos são codificados através de identificadores (IDs) numéricos, enquanto valores que originalmente possuíam casas decimais tem seus pontos flutuantes removidos. Dessa forma, os dados se apresentam conforme ilustrado pela figura 3:

src > data > microdados > amostra_domicilios_2010_SC.txt

```
1   4200051420005100100100000745003486869475141940300900201115   3060030
2   4200051420005100100100029472003523739097269840300900201111   3060030
3   4200051420005100100100049362002259614086741440300900201111   1070040
4   4200051420005100100100072173003709996388955640300900101111   3050040
5   4200051420005100100100073380003724660209393340300900201111   1080030
6   4200051420005100100100076708004465496693169140300900101111   3050060
7   4200051420005100100100091389003724660209393340300900201111   1090020
8   4200051420005100100100094224004702878043781240300900101111   1070070
9   4200051420005100100100102234002906904385943840300900101111   1070040
10  4200051420005100100100112068002776637222533540300900201111   3090030
```

Figura 3 – Exemplo de microdados: primeiras 10 linhas da pesquisa de Domicílios do Censo de 2010 no estado de Santa Catarina. Fonte: Dados do Autor (2023).

Juntamente com os microdados, é fornecido uma planilha no formato *Open Document Spreadsheet* (ODS) ou Excel que descreve o que cada caractere do arquivo significa,

[2] Para mais detalhes, consulte <www.ibge.gov.br/estatisticas/todos-os-produtos-estatisticas.html>. Acesso em 03 out. 2023

relacionando as categorias e identificadores e a formatação referente às casas decimais das variáveis numéricas.

Tomando como exemplo a amostra da pesquisa de domicílios do Censo Demográfico de 2010, o arquivo de *layout* [3] (exemplificado na figura 4), temos que as duas primeiras posições do arquivo referem-se variável V0001 à UF, cujo valor 42 corresponde ao Estado de Santa Catarina. Outro exemplo significativo é a variável numérica V0010, Peso Amostral, engloba os dígitos da posição 29 até 44, sendo os 3 primeiros (coluna INT) os dígitos anteriores ao ponto decimal, e as 13 subsequentes sendo as casas de precisão após a vírgula (coluna DEC).

VAR	NOME	POSIÇÃO INICIAL	POSIÇÃO FINAL	INT	DEC	TIPO
V0001	UNIDADE DA FEDERAÇÃO: 41- Paraná 42- Santa Catarina 43- Rio Grande do Sul 50- Mato Grosso do Sul	1	2	2		A
V0002	CÓDIGO DO MUNICÍPIO	3	7	5		A
V0010	PESO AMOSTRAL	29	44	3	13	N
V1006	SITUAÇÃO DO DOMICÍLIO: 1- Urbana 2- Rural	53	53	1		C

Figura 4 – Recorte da planilha de *layout* da pesquisa de domicílios do Censo Demográfico de 2010. Fonte: Dados do Autor (2023).

Variáveis padrões contidas nas pesquisas são as referentes à localização geográfica como município, UF e área de ponderação, assim como o peso amostral, que por sua vez é uma medida de representatividade daquela resposta dentro do escopo da pesquisa.

Os arquivos de microdados ficam disponíveis através da URL <www.ibge.gov.br/estatisticas/sociais/trabalho/22827-censo-demografico-2022.html?edicao=37225&t=microdados>, separados por Estado e por Censo, hoje[4] estando disponíveis os microdados Censos de 2000 e 2010 no *website*. Com o intuito de facilitar o processo de baixar os arquivos, foi codificado um *script python*[5] para tal, que realiza o *download* de todos os arquivos `.zip`, descompacta eles e então os renomeia, de modo a padronizar os nomes dos arquivos de ambas pesquisas e separar as diferentes amostras, além de separar arquivos de dados dos arquivos auxiliares que estão inclusos nos diretórios compactados. Vale ressaltar que os arquivos não processados não foram incluídos no repositório por conta do limite máximo de 100 megabytes (MB) que o *Github* impõe para os arquivos.

Após extraídos os `zip`s, tem-se uma coleção de arquivos de texto (de extensão `.txt`) contendo os microdados codificados como na figura 3. Para transformá-los em dados

[3] Arquivo /Documentação/Layout/Layout_microdados_amostra.xls. Download em: <ftp.ibge.gov.br/Censos/Censo_Demografico_2010/Resultados_Gerais_da_Amostra/Microdados/Documentacao.zip>. Acesso em 03 out. 2023.

[4] Considerando o último acesso em novembro de 2023.

[5] Código completo no arquivo download-arquivos-microdados.ipynb, disponível em: <github.com/GDevigili/TCC-IBGE/blob/main/src/notebooks/download-arquivos-microdados.ipynb>

utilizáveis, os microdados precisam ser associados aos respectivos valores, descritos no arquivo de *layout*.

Inicialmente, tentou-se fazer tal "tradução" via *python*[6], manualmente programando tal a associação dos IDs com suas respectivas *labels*. Primeiramente destrinchando o arquivo de descrição das variáveis em pares chave-valor e dividindo os números dos microdados em colunas de acordo com as respectivas posições inicial e final, armazenando ambos os resultados deste pré-processamento em `DataFrame` da biblioteca `pandas`. Tendo em mãos os objetos necessários, foi iterado através de cada linha e coluna, substituindo os identificadores por suas respectivas *labels*.

Porém, o custo computacional de se processar os dados dessa forma, ainda mais utilizando uma linguagem *python*, conhecida por um tempo de execução elevado, além da presença de *bugs* no código devido ao funcionamento de algumas estruturas de dados da `pandas`, foi optado por realizar o mesmo trabalho utilizando o *software Stata* (em sua versão 18.0), que possui funções já implementadas para o processamento de arquivos como os do IBGE.

Com comandos da linguagem própria do *Stata*, é possível fazer a mesma associação de identificadores e labels com alguns poucos comandos, para então gerar um arquivo de dados de extenção `.dta` que posteriormente poderá ser utilizado como *dataset*. Por exemplo, no *Listing* 2 definimos a posição das variáveis, sua tipagem, respectivas *labels* e possíveis valores, nos casos de colunas categóricas, ou formatação, em caso de colunas numéricas.

O código exemplificado nada mais é que um pequeno recorte do arquivo[7] completo da pesquisa de domicílios, que conta com 76 variáveis e mais de 6 mil *labels*, em sua maioria referentes à localização geográfica da coleta da amostra, já que estão inclusos mais de 5 mil municípios e 500 microrregiões.

Para não ser necessário definir manualmente cada uma das variáveis, aproveitou-se parte do código que seria descartada na tentativa de realizar a "tradução" dos microdados via *python* e se utilizou do processamento da tabela de *layout* para gerar um *DataFrame* contendo os pares chave-valor utilizados para mapear via comando `label define` as possíveis *labels* de cada uma das colunas utilizando um *script* que itera sobre a tabela processada.

Além disso, como os códigos de município, micro e mesorregião ficam em planilhas auxiliares, foi optado por utilizar dos dados coletados via API para associar os respectivos códigos no *Dofile* que seria executado no *Stata* para gerar o conjunto de dados. A única

[6] Código completo no arquivo translate-microdata.ipynb, disponível em <github.com/GDevigili/TCC-IBGE/blob/main/src/notebooks/old-notebooks/2-translate-microdata.ipynb>

[7] Arquivo amostra_domicilios_2010.do, disponível em <https://github.com/GDevigili/TCC-IBGE/blob/main/src/do-files/amostra_domicilios_2010.do>

```
* Define as posições onde se encontram cada dado
quietly infix                  ///
  byte     V1006    53-53      ///
  double     V6204    82-84    ///
using `"amostra_domicilios_2010_RJ.txt"', clear
* Define a formatação dos dados numéricos
* Neste caso,  o dado deve assumir a formatação 0000.0
format V6204 %04.1f
* Define as labels para os dados
label var V1006    `"SITUAÇÃO DO DOMICÍLIO"'
label var V6204    `"DENSIDADE DE MORADOR / DORMITÓRIO  "'
* Define os pares chave-valor para cada variável
label define V1006_lbl 1 `" Urbana"', add
label define V1006_lbl 2 `" Rural"', add
* Associa os valores da variável V1006 com os pares chave-valor
   armazenados em V1006_lbl
label values V1006 V1006_lbl
```

Listing 2 – Exemplo de comandos Stata utilizados para"traduzir" os microdados.

transformação necessária foi o uso de uma coluna auxiliar que juntava o código da UF com os códigos de município e regiões, já que a API utiliza chaves concatenadas como identificadores.

Após gerado o *Dofile* através do *script python* descrito acima, só é necessário carregar o arquivo no *Stata* e executá-lo, por fim salvando o novo arquivo de dados.

4 Estudo de Caso

5 Conclusão

Referências

ENCARNAÇÃO, Paulo; Maurício Schueler da. **Guia do Censo: Operação Censitária**. [S.l.]: Coordenação de Comunicação Social - IBGE., 2010. Disponível em: <https://censo2010.ibge.gov.br/materiais/guia-do-censo/operacao-censitaria.html>.

IBGE. **API de dados agregados do IBGE**. [S.l.]: IBGE (Instituto Brasileiro de Geografia e Estatística), 2017. Disponível em: <https://servicodados.ibge.gov.br/api/docs/agregados?versao=3>.

_____. Censo Demográfico: Microdados, 201-?

Apêndices

APÊNDICE A – Códigos

Este apêndice contém os algoritmos, códigos, *scripts* e funções utilizadas para o desenvolvimento do trabalho que são citadas o longo do decorrer da dissertação. O conjunto completo dos arquivos de código se encontra no diretório `/src` do repositório do *Github* <github.com/GDevigili/TCC-IBGE>.

A.1 Algoritmo de *Unnesting*

O presente algoritmo realiza o processo de *unnesting*, que visa o nivelamento de uma estrutura de dados em nível único, duplicando dados quando necessário. O processo de desaninhamento sobe os dados de um valor "filho" (de grau inferior) até o nível de seu valor "pai" (de grau imediatamente superior) de forma recursiva.

```python
def unnest_json(json_dict: dict, col_name: str = '') -> dict:
    output = {}
    def flatten(column, col_name:str = ''):
        # Se a coluna é do tipo dict, continua a recursão
        if type(column) == dict:
            for key in column:
                # Determina o nome da coluna para cada chave (
                    key)
                if col_name == '':
                    new_col_name = str(key)
                else:
                    # adiciona o pai da coluna ao seu nome
                    parent_col = col_name.split('_')[-1]
                    new_col_name = parent_col + '_' + str(key)
                # Chama recursivamente a função flatten para a
                    chave atual
                flatten(column[key], new_col_name)
        else:
            # Se a coluna não é do tipo dict, salva o valor dela
                no output
            output[col_name] = column
    flatten(json_dict, col_name)
    return output
```

Listing 3 – Algoritmo de *unnesting* em *python*.

A.2 Algoritmo de conversão de *string* JSON para um objeto do tipo *pandas.DataFrame*

O *script* abaixo converte um objeto do tipo *string* contendo um código JSON para um objeto do tipo `DataFrame` da biblioteca `pandas`, para tal, utilizando a função de *unnesting*, presente em *listing* 3. Um exemplo de uso é a conversão do exemplo em *listing* 1 da sessão 3.1 para a tabela 1.

```
import pandas as pd

def make_df(json_dict: dict) -> pd.DataFrame:
    """Return a DataFrame from a json dict.

    Args:
        json_dict (dict): A dict containing the json data.

    Returns:
        pd.DataFrame: A DataFrame with the data.
    """
    # Create a list to store the rows
    rows = []
    # Iterate over each item on the json dict
    for item in json_dict:
        # Unpack the json dict into a single row dict
        row = unpack_json(item)
        # Add the row to the list
        rows.append(row)
    # Create a DataFrame from the rows list
    df = pd.DataFrame(rows)
    return df
```

Listing 4 – Algoritmo de transformação de *string* JSON para um objeto do tipo *pandas.DataFrame*.

A.3 Adaptador HTTP customizado

Devido ao erro `UNSAFE_LEGACY_RENEGOTIATION_DISABLED` encontrado ao tentar realizar requisições às APIs do IBGE utilizando sistemas operacionais baseados em *Linux* (foi utilizado Ubuntu 20 nos testes), foi necessário criar um adaptador customizado do

Hypertext Transfer Protocol (HTTP) utilizando um contexto legado do protocolo *Secure Sockets Layer* (SSL).

```
import requests
import urllib3
import ssl

class CustomHttpAdapter (requests.adapters.HTTPAdapter):
    """Transport adapter that allows us to use custom
       ssl_context."""
    def __init__(self, ssl_context=None, **kwargs):
        self.ssl_context = ssl_context
        super().__init__(**kwargs)

    def init_poolmanager(self, connections, maxsize, block=False
        ):
        self.poolmanager = urllib3.poolmanager.PoolManager(
            num_pools=connections, maxsize=maxsize,
            block=block, ssl_context=self.ssl_context)

def get_request():
    """Return a requests session with a custom SSL context."""
    ctx = ssl.create_default_context(ssl.Purpose.SERVER_AUTH)
    ctx.options |= 0x4  # OP_LEGACY_SERVER_CONNECT
    session = requests.session()
    session.mount('https://', CustomHttpAdapter(ctx))
    return session

def get_request_json(url: str)-> dict:
    """Return a json from a request."""
    response = get_request().get(url)
    return response.json()
```

Listing 5 – Algoritmo de transformação de *string* JSON para um objeto do tipo *pandas.DataFrame*.

A.4 *Script* para a carga de indicadores da API de países

O código a seguir realiza requisições para a API de países do serviço de dados do IBGE, retornando um conjunto de dados com 34 indicadores de 193 países. O módulo

`utils` importado no *script* está no diretório `src` do repositório do *Github*. As funções utilizadas são `make_df()` e `get_request_json()` (*listings* 4 e 5, respectivamente).

```
import pandas as pd
from utils import *

url_paises = "https://servicodados.ibge.gov.br/api/v1/paises/"
df_paises = make_df(get_request_json(url_paises))
df_paises = df_paises.rename(columns={
    'id_M49': 'id-pais'
    ,'id_ISO-3166-1-ALPHA-2': 'sigla-2'
    ,'id_ISO-3166-1-ALPHA-3': 'sigla-3'
})
url_indicadores = "https://servicodados.ibge.gov.br/api/v1/
   paises/indicadores/"
df_indicadores = make_df(get_request_json(url_indicadores))

country_list = df_paises['sigla'].unique()
indicator_list = df_indicadores['id'].unique()

df_country_indicators = pd.DataFrame()
for country in country_list:
    # making the request
    url_country = f"https://servicodados.ibge.gov.br/api/v1/
       paises/{country}/indicadores"
    df_country = make_df(get_request_json(url_country))
    # unpacking the lists
    # take the series dict out of the list (there will be always
        one or zero values on the list)
    df_country = df_country.explode('series')
    # get the country code (e.g. BR) and country name from the
       series country and concat it into each of the df_country
       lines
    df_country = pd.concat([df_country, pd.json_normalize(
       df_country['series'])], axis = 1)
    # drop the column series as it won't be used anymore
    df_country = df_country.drop('series', axis = 1)
    # unpack the values for each date
    df_country = df_country.explode('serie')
    df_country['ano'] = df_country['serie'].apply(lambda x: list
```

```
    (x.keys())[0] if type(x) == dict else None)
df_country['valor_indicador'] = df_country['serie'].apply(
    lambda x: list(x.values())[0] if type(x) == dict else
    None)
df_country = df_country.drop('serie', axis = 1)
df_country_indicators = pd.concat([df_country_indicators,
    df_country], ignore_index=True)
```

Listing 6 – *Script* de carga dos indicadores da API de países.